



UNIVERZITET MEDITERAN
FAKULTET ZA INFORMACIONE TEHNOLOGIJE

PREPOZNAVANJE EMOCIJA POMOĆU MULTIMODALNOG PRISTUPA

SPECIJALISTIČKI RAD

Oblast: Softversko inženjerstvo

Ime i prezime studenta: Lana Ivanović

Mentor: Prof. dr Tijana Marković

Broj indeksa: S23-24

Podgorica, septembar 2025.

Predgovor

Ovaj specijalistički rad predstavlja nastavak i proširenje istraživačkog rada koji sam započela tokom studentskog boravka na Fakultetu za inovacije, dizajn i inženjering na Univerzitetu Mälardalen u Švedskoj u sklopu ERASMUS+ razmjene. Tokom tog perioda radila sam na projektu *Multimodal Emotion Recognition: MobileNetV2 Late Fusion on a Combined Dataset*, koji je poslužio kao osnov i inspiracija za dalji razvoj ove teme. Kroz praktičan rad i istraživanje ovo iskustvo mi je omogućilo stručno usavršavanje i dublje razumijevanje kompleksnosti ove tematike, posebno u kontekstu koliko vještačka inteligencija može imati zapaženu ulogu u promjeni kliničke prakse i unapređenju kvaliteta kliničkog okruženja.

Želim se zahvaliti svojim mentorima, profesorima Carlu Ahlbergu i Martinu Ekströmu, kao i kolegama sa Univerziteta Mälardalen koji su me podržali tokom studija i rada na ovom istraživanju. Posebnu zahvalnost dugujem Prof. dr Tijani Marković na njenom doprinosu i dragocjenim savjetima tokom procesa realizacije ovog rada.

Sadržaj

Predgovor	1
Spisak slika	4
Spisak tabela	5
Lista skraćenica	6
1 Uvod	8
2 Formulacija problema	10
3 Teorijski okvir	11
3.1 Istorijat demencije	11
3.2 Tehnologije i modeli za prepoznavanje emocija	12
3.3 Savremena istraživanja	13
4 Pregled literature	14
4.1 Primjena dubokog učenja u MER-u	14
4.2 Tehnike audio-vizuelne fuzije	15
5 Implementacija	17
5.1 Prikupljanje podataka	17
5.2 Ekstrakcija podataka	18
5.3 Arhitektura modela	19
5.4 Priprema podataka i postupak treniranja	20
5.5 Strategija fuzije	21
5.6 Strategija evaluacije	22
6 Rezultati	24

6.1	Generalizacija facijalnog modela	24
6.2	Generalizacija audio modela	25
6.3	Generalizacija modela fuzije	27
6.4	Uporedna analiza	28
7	Budući pravci istraživanja	30
8	Zaključak	32
	Literatura	33

Spisak slika

1	Dimenzionalni model emocija prema Russellu, prikazan u obliku kružnog rasporeda sa osama uzbuđenja (<i>engl. arousal</i>) i valence. Preuzeto sa: [16]	12
2	Vizualizacija ekstrakcije karakteristika iz audio i video signala	19
3	Dvije nezavisne grane za audio i slike lica, koje se spajaju u fuzionom sloju . . .	20
4	Normalizovane matrice konfuzije za facijalni model u cross-corpus evaluaciji (trenirani na objedinjeni skup, testirani na EmoDB i RAVDESS).	25
5	Normalizovane matrice konfuzije za audio model u cross-corpus evaluaciji (trenirani na objedinjeni skup, testirani na EmoDB i RAVDESS).	26
6	Normalizovana matrica konfuzije za fuzioni model u cross-corpus evaluaciji (trenirano na objedinjeni skup, testirano na EmoDB i RAVDESS).	28
7	Performanse modela na test podskupu objedinjenih podataka	29

Spisak tabela

1	Korišćeni skupovi podataka u istraživanju	17
2	Tačnost facijalnog modela na RAVDESS (cross-corpus)	24
3	Tačnost audio modela na EmoDB (cross-corpus)	25
4	Tačnost modela fuzije na EmoDB + RAVDESS (cross-corpus)	27
5	Analiza prisutnosti disbalansa polova kod različitih skupova podataka	30

Lista skraćenica

DP	Deep Learning
HCI	Human-Computer Interaction
FER	Facial Expression Recognition
SER	Speech Emotion Recognition
AI	Artificial Intelligence
BPSD	Behavioral and Psychological Symptoms of Dementia
ML	Machine Learning
MER	Multimodal Emotion Recognition
BCI	Brain-Computer Interface
CNN	Convolutional Neural Network
MSA	Multimodal Sentiment Analysis
CNNs	Convolutional Neural Networks
RNN	Recurrent Neural Network
ONN	Operational Neural Network
VIT	Vision Transformer
Adam	Adaptive Moment Estimation
NHMRC	National Health and Medical Research Council
RAVDESS	Ryerson Audio-Visual Database of Emotional Speech and Song

RML	Ryerson Multimedia Laboratory
IEMOCAP	Interactive Emotional Dyadic Motion Capture
AFEW-VA	Affective Computing and Emotion Recognition - Valence-Arousal Dataset
SAVEE	Surrey Audio-Visual Expressed Emotion
eNTERFACE	Audio-Visual Emotion Database
CREMA-D	Crowd-Sourced Emotional Multimodal Actors Dataset
FER2013	Facial Expression Recognition 2013 Dataset
EmoDB	Emotional Speech database
EEG	Electroencephalography
HR	Heart Rate
GSR	Galvanic Skin Response
MFCC	Mel-Frequency Cepstral Coefficients
RMS	Root Mean Square Energy
ZCR	Zero-Crossing Rate
RetinaFace	RetinaFace Detector
SpecAugment	Spectrogram Augmentation
CM	Confusion Matrix

1. Uvod

Emocije predstavljaju složen skup psiholoških i fizioloških procesa koji značajno utiču na način na koji ljudi percipiraju, tumače i reaguju na spoljašnje i unutrašnje stimulanse i reakcije [1, 2]. Prema klasičnim teorijama psihologije, emocije su povezane sa promjenama u autonomnom nervnom sistemu, hormonalnim reakcijama i izražavaju se kroz ponašanje, izraze lica (*engl. facial expressions*), ton glasa i govor tijela [2]. Precizno prepoznavanje emocija od suštinskog je značaja za razumijevanje međuljudske komunikacije, jer emocije posreduju u procesima odlučivanja, učenja i socijalne interakcije. U savremenom digitalnom društvu, sposobnost automatskog prepoznavanja emocija dobija na važnosti jer omogućava razvijanje sistema koji bolje razumiju korisnike i prilagođavaju se njihovim potrebama.

Tehnike automatskog prepoznavanja emocija nalaze široku primjenu u različitim domenima [3]. U oblasti interakcije čovjek–računar (*engl. Human-Computer Interaction (HCI)*), sistemi za detekciju emocionalnog stanja omogućavaju prilagodbu ponašanja računara ili softvera emocionalnom stanju korisnika, čime se poboljšava korisničko iskustvo i intuitivnost interfejsa [4]. U automobilske industriji, prepoznavanje emocija vozača koristi se za nadzor stanja budnosti i stresa, čime se povećava sigurnost u saobraćaju. Industrija zabave koristi ovakve tehnologije za personalizaciju sadržaja i kreiranje adaptivnog interaktivnog okruženja. Posebno značajna primjena ostvaruje se u medicini i zdravstvenoj zaštiti, gdje sistemi za prepoznavanje emocija doprinose dijagnostici, monitoringu i terapiji različitih psiholoških i neuroloških stanja [5].

Većina tradicionalnih sistema koristi samo jedan modalitet, facijalne ekspresije ili govor, ali su takvi unimodalni modeli često ograničeni promjenjivim uslovima okoline [6]. Multimodalni pristup kombinuje više izvora signala, što značajno povećava pouzdanost i robustnost sistema za prepoznavanje emocija [3]. Tradicionalni pristupi prepoznavanju emocija često su zasnovani na korišćenju jednog modaliteta, kao što su analiza facijalnih ekspresija (*engl. Facial Expression Recognition (FER)*) [6] ili prepoznavanje emocija iz govora (*engl. Speech Emotion Recognition (SER)*). Međutim, istraživanja pokazuju da unimodalni sistemi imaju značajna ograničenja

u realnim uslovima zbog osjetljivosti na faktore okoline, poput promjena u osvjetljenju, buke u pozadini ili maskiranja izraza lica. Multimodalni pristup, koji kombinuje različite izvore signala (npr. facijalne ekspresije, govor, fiziološke signale), omogućava robusnije i pouzdanije prepoznavanje emocija jer nadoknađuje slabosti pojedinačnih modaliteta [3]. Zahvaljujući napretku u obradi signala i razvoju dubokih neuronskih mreža, multimodalni sistemi postali su tehnički izvodljivi i spremni za implementaciju u različite praktične scenarije.

Jedna od značajnih primjena multimodalnog prepoznavanja emocija nalazi se u zdravstvenoj zaštiti. Poseban izazov za prepoznavanje emocija predstavlja rad sa pacijentima koji zbog zdravstvenog stanja gube sposobnost jasne verbalne i neverbalne komunikacije. Demencija je jedno od najčešćih neurodegenerativnih oboljenja koje uzrokuje postepeno pogoršanje kognitivnih funkcija, gubitak pamćenja i smanjenje sposobnosti izražavanja emocija i potreba [7]. Upravo zbog toga, rano otkrivanje emocionalnog distresa i ponašajnih i psiholoških simptoma demencije (*engl. Behavioral and Psychological Symptoms of Dementia (BPSD)*) od izuzetne je važnosti za planiranje odgovarajuće njege i terapije. Savremeni multimodalni sistemi za prepoznavanje emocija nude mogućnost detekcije suptilnih signala koji bi mogli ukazivati na promjene u emocionalnom stanju, a koje medicinsko osoblje ili porodica možda neće uočiti na vrijeme. Time se doprinosi pravovremenoj intervenciji i poboljšanju kvaliteta života pacijenata i njihovih negovatelja.

Cilj ovog specijalističkog rada je razvoj i evaluacija sistema za automatsko prepoznavanje emocija pomoću multimodalnog pristupa koji integriše facijalne i audio signale, uz primjenu savremenih tehnika veštačke inteligencije (*engl. Artificial Intelligence (AI)*) i mašinskog učenja (*engl. Machine Learning (ML)*). Fokus je stavljen na detekciju šest osnovnih emocija, s posebnim naglaskom na negativna afektivna stanja relevantna za prepoznavanje BPSD simptoma kod pacijenata sa demencijom. Na taj način, rad ima za cilj da doprinese budućem razvoju praktičnih i pouzdanih alata koji bi mogli imati primjenu u kliničkom okruženju i unaprijediti kvalitet zdravstvene zaštite i njege pacijenata.

2. Formulacija problema

U cilju podrške ranom prepoznavanju emocionalnog distresa u procesu pružanja zdravstvenih usluga osobama sa demencijom, ovaj rad je usmeren na razvoj sistema za prepoznavanje emocija uz multimodalni pristup (*engl. Multimodal Emotion Recognition (MER)*) koji kombinuje audio i vizuelne podatke. Imajući u vidu ograničenja unimodalnih (jednomodalnih) pristupa u realnim uslovima i njihovu zavisnost od visokokvalitetnih podataka, istraživanje obuhvata upotrebu heterogenih skupova podataka i primjenu kasne integracije (*engl. late fusion*) kako bi se poboljšala otpornost (*engl. robustness*) i generalizacija modela.

Primarni cilj je da se procijeni na koji način kombinacija više javno dostupnih skupova podataka i integracija na nivou odluke mogu unaprijediti sposobnost sistema da detektuje šest osnovnih emocija, sa posebnim naglaskom na negativna emocionalna stanja povezana sa BPSD.

Istraživanje je vođeno sledećim istraživačkim pitanjima:

IP1: Kako treniranje na kombinovanom skupu heterogenih podataka ima uticaj na tačnost i generalizaciju modela?

IP2: Kakav je uticaj kasne fuzije audio i facijalnih signala, korišćenjem kombinovanih heterogenih skupova podataka, na tačnost i generalizaciju modela za prepoznavanje emocija?

3. Teorijski okvir

U ovom poglavlju razmatraju se ključni teorijski koncepti i tehnološke osnove vezane za prepoznavanje emocija, sa posebnim osvrtom na njihovu primjenu u kontekstu njege osoba sa demencijom. Proučava se kako su se modeli prepoznavanja emocija razvijali kroz vrijeme, kao i na koji način savremeni multimodalni pristupi omogućavaju dublje razumijevanje emocionalnog stanja pacijenata kod kojih verbalna komunikacija postaje otežana. Kroz ovaj teorijski okvir biće predstavljene osnove multimodalne analize, relevantne psihološke i neurološke pretpostavke, kao i aktuelni izazovi u implementaciji takvih sistema u kliničku praksu.

3.1. Istorijat demencije


Demencija predstavlja jedno od najučestalijih neurodegenerativnih oboljenja, koje pogađa milione ljudi širom svijeta. Kroz istoriju, pojam demencije se razvijao od opštih opisa „senilnosti“ do preciznijih medicinskih definicija. U 20. vijeku, zahvaljujući istraživanjima poput onih Aloisa Alzheimer [8, 9], došlo je do značajnog napretka u razumijevanju anatomskih i bioloških osnova bolesti. Danas se pod demencijom podrazumijeva skup različitih simptoma koji uključuju gubitak pamćenja, smanjene kognitivne funkcije, promjene u ponašanju i poteškoće u verbalnoj i neverbalnoj komunikaciji. Prema Nacionalnom odboru za zdravlje i medicinska istraživanja (*engl. National Health and Medical Research Council (NHMRC)*) [10], rana dijagnostika i planiranje individualizovane njege su ključni za očuvanje kvaliteta života oboljelih.

Strategije brige o osobama sa demencijom značajno su se razvijale tokom istorije. Od institucionalizacije i restriktivnih metoda krajem 19. vijeka, preko upotrebe antipsihotika sredinom 20. vijeka, pa sve do savremenih, personalizovanih pristupa koji naglašavaju pažljivu i prilagodljivu negu. Savremeni modeli ističu da bihevioralni i psihološki simptomi demencije (BPSD), poput agresije, agitacije, depresije ili apatije, često ukazuju na neprepoznate emocionalne ili fiziološke potrebe pacijenata. Kako bolest napreduje, oštećenje kognitivnih funkcija i komunikacije otežava pacijentima da jasno izraze svoja emocionalna stanja, zbog čega se rani

znaci distresa lako mogu prevideti dok simptomi ne eskaliraju [11]. Efikasno upravljanje BPSD sve više zavisi od pravovremene i tačne identifikacije emocionalnih signala, kako bi se omogućile proaktivne, nefarmakološke intervencije, poput prilagođavanja okruženja ili terapijskog angažmana, čime se značajno doprinosi dobrobiti pacijenata [12].

3.2. Tehnologije i modeli za prepoznavanje emocija

Proučavanje emocija decenijama je oblikovano različitim teorijskim modelima koji nastoje objasniti kako se emocije doživljavaju i izražavaju. Fiziološki indikatori, kao što su ubrzan rad srca prilikom osećaja straha, spontani osmeh pri osjećaju sreće ili suze izazvane tugom, čine osnovu za razumijevanje i detekciju emocionalnih stanja. Paul Ekman je 1970-ih godina formulisao teoriju o šest osnovnih emocija, koje su biološki urođene i univerzalno prepoznatljive širom kultura, uz određene razlike u intenzitetu [13]. Ove osnovne emocije su: sreća, tuga, strah, gađenje, ljutnja i iznenađenje. Danas postoje dva dominantna modela za klasifikaciju emocija: diskretni model, koji emocije posmatra kao odvojene kategorije (npr. šest osnovnih emocija), i dimenzionalni model, koji prikazuje emocije kao tačke u kontinuiranom prostoru sa dve ili tri dimenzije, poput Russellovog (Slika 1) ili Mehrabianovog modela [14, 15]. Ovi modeli čine teorijsku osnovu za dizajn savremenih sistema za prepoznavanje emocija.



Slika 1: Dimenzionalni model emocija prema Russellu, prikazan u obliku kružnog rasporeda sa osama uzbuđenja (*engl. arousal*) i valence. Preuzeto sa: [16]

Sa tehničkog aspekta, pouzdano prepoznavanje i snimanje emocionalnih stanja predstavlja

izazov. Fiziološki signali, poput mikro-ekspresija lica ili intonacije glasa, značajno variraju u zavisnosti od konteksta, individualnih karakteristika i okruženja. Iako su sistemi za facijalno prepoznavanje emocija (FER) i prepoznavanje emocija na osnovu govora (SER) pokazali dobre rezultate u kontrolisanim uslovima, njihova samostalna primjena često je ograničena u realnim situacijama [3]. Zbog toga se sve više pažnje posvećuje multimodalnom prepoznavanju emocija (MER). Ovi sistemi kombinuju više senzorskih ulaza, najčešće izraze lica, govorne signale, kao i EEG (*engl. Electroencephalography (EEG)*) podatke, i tako omogućavaju robusniju i sveobuhvatniju procjenu afektivnih stanja [14]. Integracija više modaliteta kompenzuje ograničenja jednomodalnih sistema i povećava otpornost na šumove i varijabilnosti u realnim okruženjima.

3.3. Savremena istraživanja

Cai i saradnici (2023) [3] pružaju sveobuhvatan pregled senzora, emocionalnih modela i skupova podataka koji se koriste u MER istraživanjima. Posebno ističu značaj naprednih tehnika integracije (*engl. fusion*) zasnovanih na pažnji (*engl. attention-based fusion*), koje povezuju facijalne i govorne karakteristike za pouzdaniju identifikaciju emocija. Alternativni modaliteti, poput interfejsa mozak–računar (*engl. Brain-Computer Interface (BCI)*), dodatno proširuju mogućnosti MER sistema, naročito za pacijente kod kojih su verbalna i facijalna ekspresija ograničene [14]. Khare i saradnici [15] naglašavaju kako vještačka inteligencija (*engl. Artificial Intelligence (AI)*) i sistemi za prepoznavanje emocija sve više nalaze primjenu u zdravstvu, obrazovanju i drugim oblastima, istovremeno otvarajući nova etička i istraživačka pitanja. Ghorbanali i Sohrabi (2023) [11] u svojoj opsežnoj analizi ističu ključnu ulogu dubinskog učenja i pametnih algoritama u unapređenju tačnosti i prilagodljivosti MER sistema.

Primjena ovih tehnologija u kliničkom okruženju ima poseban značaj za rad sa osobama oboljelim od demencije. Multimodalni sistemi omogućavaju kontinuirano, neinvazivno praćenje emocionalnih signala, što medicinskom osoblju daje alate za raniju intervenciju i personalizovanu njegu. Međutim, uprkos napretku, izazovi poput generalizacije na heterogenim skupovima podataka i detekcije suptilnih, prolaznih emocionalnih reakcija i dalje ostaju otvoreni [11]. Stoga, aktuelna istraživanja sve više usmjeravaju pažnju ka razvoju robustnih MER sistema, prilagođenih realnim kliničkim uslovima, kako bi se olakšalo prepoznavanje ranih znakova BPSD i poboljšao kvalitet života pacijenata i njihovih negovatelja.

4. Pregled literature

Ovo poglavlje prikazuje kritički pregled savremenih dostignuća u oblasti prepoznavanja emocija zasnovanog na više modaliteta (MER), sa posebnim naglaskom na tehnike audio-vizuelne fuzije, evoluciju modela dubokog učenja i njihovu integraciju u arhitekture sistema koji se koriste u realnim uslovima.

Prepoznavanje emocija putem izraza lica i govora predmet je intenzivnih istraživanja, pri čemu su razvijeni brojni pristupi za tačno tumačenje emocionalnih stanja. Noviji radovi u oblasti MER sve više se fokusiraju na integraciju više modaliteta: vizuelnih, auditivnih i lingvističkih podataka, kako bi se poboljšala tačnost i robusnost sistema za detekciju emocija, naročito u aplikacijama u realnom vremenu [3]. Postojeći pregledi uglavnom analiziraju MER kroz integraciju audio i vizuelnih podataka, dok se fiziološki signali poput elektroencefalograma (EEG), kožne provodljivosti (*engl. Galvanic Skin Response (GSR)*) i otkucaja srca (*engl. Heart Rate (HR)*) često zanemaruju [17]. Dodatno, suptilne dinamike mikronekspresija lica, koje su ključne za prepoznavanje skrivenih ili nijansiranih emocija, u velikoj mjeri ostaju neadekvatno obrađene tokom faza dizajna i evaluacije ovakvih sistema.

4.1. Primjena dubokog učenja u MER-u

Duboko učenje (*engl. Deep Learning (DP)*) imalo je presudan uticaj na razvoj sistema za multimodalno prepoznavanje emocija. Detaljan pregled literature koji su sproveli Ghorbanali i Sohrabi [11] obuhvata širok spektar modela dubokog učenja primijenjenih u analizi multimodalnih podataka (*engl. Multimodal Sentiment Analysis (MSA)*), ističući izazove kao što su nepotpuni podaci, višak informacija i strategije optimalne fuzije. Slično tome, sistematski pregled koji su sproveli Sahu i saradnici [18] analizira različite alate za prikupljanje emocija i arhitekture dubokog učenja, sa fokusom na njihovu efikasnost u MER zadacima. Studija identifikuje konvolucione neuronske mreže (*engl. Convolutional Neural Networks (CNNs)*), rekurentne neuronske mreže (*engl. Recurrent Neural Networks (RNNs)*) i transformatore kao dominant-

ne pristupe u okviru MER sistema, ističući njihovu sposobnost da efikasno uče hijerarhijske i vremenske karakteristike iz višemodalnih podataka.

Nedavni radovi naglašavaju značaj unapređenja metoda za fuziju dubokih karakteristika i učenja među modalitetima, što je rezultiralo značajnim poboljšanjima u tačnosti modela na skupovima podataka kao što su Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS) i Crowd-Sourced Emotional Multimodal Actors Dataset (CREMA-D) [19]. Moderni modeli sve više koriste unaprijed obučene arhitekture i mehanizme pažnje za višemodalnu obradu, s ciljem boljeg hvatanja složenih odnosa između auditivnih i vizuelnih signala. Ipak, oslanjanje na visokokvalitetne i vremenski sinhronizovane podatke i dalje predstavlja izazov u praktičnoj primjeni. Godine 2024, Srihari i saradnici [20] predstavili su sistem za MER koji kombinuje govor i izraze lica, ostvarujući tačnost od 97,2% na RAVDESS skupu korišćenjem jednostavne strategije kasne fuzije na osnovu specijalizovanih CNN modela za svaki modalitet. Autori naglašavaju efikasnost specifičnih arhitektura: duboka 1D CNN sa pet slojeva pokazala se kao najefikasnija za audio (78,76%), dok je plića 2D CNN sa dva sloja dala najbolje rezultate za video (84,57%).

Poseban značaj dat je inženjeringu karakteristika, gdje su za obradu zvuka korišćeni Zero-Crossing Rate (ZCR), Root Mean Square Energy (RMS) i Mel-Frequency Cepstral Coefficients (MFCC) parametri, dok je za obradu lica upotrebljen unaprijed trenirani vizuelni transformator (*engl. Vision Transformer (ViT)*), čime su izvučene robusne karakteristike iz izolovanih kadrova lica. Rezultati studije pokazuju da strategija kasne fuzije može uspješno iskoristiti komplementarnu prirodu audio i vizuelnih signala u procesu predikcije emocija.

4.2. Tehnike audio-vizuelne fuzije

U okviru MER, efikasna integracija signala iz različitih izvora, poput zvuka i slike, predstavlja jedan od ključnih izazova. Literatura identifikuje dvije dominantne strategije fuzije: fuziju na nivou karakteristika (*engl. feature-level fusion*) i fuziju na nivou odluke (*engl. decision-level fusion*) [3]. Fuzija na nivou karakteristika podrazumijeva spajanje značajki iz svakog modaliteta (npr. karakteristike izraza lica i visina glasa) prije samog procesa klasifikacije. Ova metoda je računski efikasna i omogućava očuvanje informacija iz oba izvora, ali je istovremeno osjetljiva na šum i nedostatak podataka [21]. S druge strane, fuzija na nivou odluke, poznata i kao kasna fuzija, uključuje zasebne klasifikatore za svaki modalitet.

Svaki klasifikator nezavisno obrađuje svoj modalitet (npr. ekspresije lica ili ton glasa), na-

kon čega se njihove odluke kombinuju pomoću različitih tehnika, kao što su većinsko glasanje, izračunavanje prosjeka gdje neki imaju veću težinu, ili naprednije metode kombinovanja [15]. Ova modularna strategija omogućava optimizaciju svakog modaliteta posebno i povećava robusnost sistema, naročito u situacijama kada je jedan modalitet degradiran, nedostupan ili zagađen šumom [21]. U takvim uslovima, sistem može nastaviti sa radom oslanjajući se na pouzdaniji modalitet. Wozniak i saradnici [22] predstavili su T-Fusion blok dizajniran za realnu vremensku fuziju, sposoban da funkcioniše čak i kada privremeno dođe do prekida u jednom od modaliteta, čime dodatno potvrđuju prednosti strategija kasne fuzije.

Dodatno, rad Aktürk i saradnika [23] predstavio je upotrebu operatornih neuronskih mreža (*engl. Operational Neural Networks (ONNs)*) kao alternativu CNN-ovima, ostvarujući bolju generalizaciju emocija i robusnost, iako se konkretne strategije fuzije u tom radu nijesu razmatrale. Kao rezultat ovih istraživanja, strategija fuzije na nivou odluke postaje sve popularnija zbog svoje modularnosti, skalabilnosti i otpornosti na heterogene i asinhronne izvore podataka.

5. Implementacija

Ovo poglavlje opisuje metodološki okvir istraživanja, uključujući pripremu podataka, ekstrakciju karakteristika, arhitekturu modela, strategije fuzije i evaluacije. Poseban akcenat stavljen je na multimodalni pristup koji integriše zvuk i vizuelne podatke radi poboljšanja prepoznavanja emocionalnog distresa kod osoba sa demencijom.

5.1. Prikupljanje podataka

U okviru istraživanja korišćeno je deset javno dostupnih skupova podataka, prikazanih u Tabeli 1. Od toga je osam skupova iskorišćeno za treniranje modela, dok su dva služila za testiranje generalizacije. Za evaluaciju generalizacije modela korišćeni su odvojeni skupovi: EMODB (audio) i RAVDESS (vizuelni modalitet), pri čemu je svaki modalitet testiran nezavisno.

Tabela 1: Korišćeni skupovi podataka u istraživanju

Naziv	Referenca	Modalitet	Upotreba	Broj instanci
RAVDESS	[24]	Vizuelni	Testiranje	~ 7k
CREMA-D	[25]	Audio	Trening	~ 7k
FER2013	[26]	Vizuelni	Trening	~ 35k
IEMOCAP	[27]	Audio	Trening	~ 12k
RML	[28]	Audio	Trening	~ 7k
AFEW-VA	[29]	Vizuelni	Trening	~ 30k
eINTERFACE	[30]	Audio	Trening	~ 1k
SAVEE	[31]	Audio	Trening	~ 500
EMODB	[32]	Audio	Testiranje	~ 500
AffectNet	[33]	Vizuelni	Trening	~ 1M

Dostupni demografski podaci pomenutih skupova podataka ukazuju na raznovrsnost u uz-

rastu (20–74 godina), jezicima (engleski, mandarinski, urdu, pandžabi, persijski, nemački, italijanski), i etničkim pozadinama (afrička, azijska, kavkaska i latinoamerička). Ova heterogenost omogućava testiranje modela u uslovima visoke varijabilnosti, čime se doprinosi evaluaciji njegovih generalizacionih sposobnosti (**IP1**).


Podaci su organizovani u dve potkategorije za unimodalnu obradu: audio i vizuelni (slike lica). Svaki skup je grupisan u šest osnovnih kategorija emocija: sreća, tuga, ljutnja, gađenje, strah i neutralno stanje.

Radi standardizacije, rijetke i nedosljedne kategorije emocija, poput "iznenađenje" i "ljutnja", uklonjene su ili agregirane (npr. "ljutnja" je uključen u "gađenje").

5.2. Ekstrakcija podataka

Proces ekstrakcije podataka obuhvata pripremu ulaznih modaliteta (video i audio) u obliku pogodnom za dalju analizu i treniranje modela. Cilj je da se iz sirovih zapisa izvuku reprezentativne karakteristike koje omogućavaju pouzdanu klasifikaciju emocija.

- **Video i 2D Slike:** Iz video zapisa izdvajaju se frejmovi sa licem pomoću algoritama RetinaFace Detector (RetinaFace) i Haar Cascade iz OpenCV biblioteke. Slike lica se potom siječu i normalizuju. Za izdvajanje karakteristika iz vizuelnog modaliteta korišćen je prilagođeni interfejs prema treniranom MobileNetV2 modelu. Ovaj interfejs omogućava učitavanje modela i izdvajanje latentnih vektora iz posljednjeg skrivenog sloja, zajedno sa predikcijom klase i softmax vjerovatnoćama.
- **Audio:** Audio zapisi se izdvajaju kao .wav fajlovi putem biblioteke moviepy, nakon čega se generišu log-Mel spektrogrami (Slika 2). Spektrogrami se tretiraju kao 2D ulazi za CNN klasifikatore.



Slika 2: Vizualizacija ekstrakcije karakteristika iz audio i video signala


5.3. Arhitektura modela

Konvolutivne neuronske mreže (CNN) predstavljaju posebnu vrstu dubokih neuronskih mreža koje su naročito efikasne u obradi podataka sa prostornom ili vremensko-frekventnom strukturom, kao što su slike, video ili spektrogrami audio signala [4]. One koriste konvolutivne slojeve koji automatski uče lokalne obrasce (npr. ivice, oblike, frekvencijske strukture) i grade hijerarhijsko predstavljanje podataka, što ih čini pogodnim za zadatke prepoznavanja i klasifikacije.

Predloženi sistem koristi paralelnu dvo-granastu arhitekturu koja obrađuje audio i vizuelne ulaze nezavisno. Svaka grana koristi isti konvolutivni neuronski enkoder MobileNetV2 [34], koji je prethodno treniran na ImageNet skupu podataka, što omogućava efikasnu inicijalizaciju i smanjuje potrebu za dugotrajnim učenjem iz temelja. Ova mreža je poznata po dobroj ravnoteži između tačnosti, brzine i memorijskog otiska, što je čini pogodnom za realno-vremenske sisteme, uključujući one u zdravstvenim okruženjima.

Obije grane su projektovane tako da primaju trokanalne dvodimenzionalne ulaze: Log-Mel spektrogrami za audio signal i RGB slike lica za vizuelni modalitet. Nakon nezavisne obrade

kroz CNN enkodere, izlazne vjerovatnoće svake grane kombinuju se korišćenjem strategije kasne fuzije, pri čemu se dobija ponderisana srednja vrijednost predikcija.



Slika 3: Dvije nezavisne grane za audio i slike lica, koje se spajaju u fuzionom sloju

Log-Mel spektrogrami se generišu iz audio signala i tretiraju kao slike dimenzija $3 \times H \times W$, omogućavajući konzistentan format ulaza za konvolutivne mreže. Sa druge strane, slike lica se ekstrahuju iz video zapisa koristeći algoritme kao što su RetinaFace i Haar Cascade, zatim se normalizuju i prilagođavaju očekivanom formatu mreže. Model se trenira za višeklasnu klasifikaciju emocija na osnovu šest univerzalnih kategorija (sreća, tuga, ljutnja, strah, gađenje, neutralno), što je u skladu sa prethodnim radovima u oblasti automatskog prepoznavanja emocija iz spektrograma i slika [3].

Iako trenutna implementacija nije primarno optimizovana za ugradne uređaje, dugoročni cilj sistema jeste razvoj energetski efikasnog i prenosivog rešenja za detekciju emocionalnog distresa u zdravstvenim okruženjima, posebno u radu sa osobama sa demencijom.

5.4. Priprema podataka i postupak treniranja

Prije samog treniranja modeli zahtijevaju određene korake obrade podataka. Podaci su podijeljeni u odnosu 80/10/10 na trening, validacioni i test skup. Nakon toga primijenjene su tehnike augmentacije kako bi se povećala robusnost modela i smanjila mogućnost prenaučivosti.

Augmentacija audio podataka: dodavanje Gaussove buke, pomijeranje tona, i Spectrogram Augmentation (SpecAugment).

Augmentacija slike: horizontalno okretanje, promjene osvetljenja i rotacija malih uglova.

Za optimizaciju parametara modela korišćen je Adaptive Moment Estimation (Adam) optimizator. Proces treniranja uključuje i ranu obustavu istog, koja prekida učenje ukoliko se validacioni gubitak ne poboljša u roku od pet epoha.

5.5. Strategija fuzije

U cilju odgovora na istraživačko pitanje **IP2**, sprovedeno je uporedno ispitivanje više tehnika kasne fuzije, sa ciljem integracije predikcija iz audio i vizuelnog modala. Fokus je stavljen na efikasnost kombinovanja izlaza modela, bez dodatnog uvođenja kompleksnosti u obradu sirovih podataka. Razmatrane su sledeće strategije:

- **Ponderisana prosječna fuzija** (*engl. Weighted Average*): predstavlja linearnu kombinaciju vjerovatnoći distribucija iz oba modala, sa parametrizacijom putem hiperparametra $\alpha \in [0, 1]$, koji određuje relativnu važnost svakog izvora:

$$\mathbf{p}_{\text{fused}} = \alpha \cdot \mathbf{p}_{\text{audio}} + (1 - \alpha) \cdot \mathbf{p}_{\text{image}} \quad (5.1)$$

- **Gated fuzija:** koristi adaptivni pristup, gde se parametar α uči tokom treniranja putem male linearne mreže (tzv. *gating network*), čime se omogućava dinamičko prilagođavanje doprinosa svakog modaliteta u zavisnosti od ulaznih karakteristika.
- **MLP fuzija:** sprovodi se spajanjem latentnih vektora iz oba modala i njihovom obradom kroz višeslojnu perceptronsku mrežu (*engl. Multi-Layer Perceptron*), koja uči nelinearnu funkciju mapiranja ka izlaznim klasama.

Nakon sprovođenja eksperimentalne evaluacije na validacionom skupu, pokazalo se da ponderisana prosječna fuzija pruža najstabilnije i najtačnije rezultate. Zbog svoje jednostavnosti i niske računarske složenosti, ova metoda je usvojena kao finalna strategija fuzije u okviru sistema.

5.6. Strategija evaluacije

Evaluacija performansi modela sprovedena je kroz tri komplementarna scenarija, sa ciljem da se odgovori na istraživačka pitanja **IP1** i **IP2** i pruži sveobuhvatna analiza tačnosti, robusnosti i doprinosa pojedinačnih modaliteta.

- **Holdout evaluacija:** Dio kombinovanog skupa podataka (10%) izdvojen je kao statički test skup za osnovnu evaluaciju. Ovaj pristup omogućava neposredno poređenje različitih arhitektura i strategija fuzije pod kontrolisanim uslovima.
- **Međuskupna (engl. *cross-corpus*) evaluacija:** Radi ispitivanja sposobnosti generalizacije (**IP1**), modeli su trenirani na: (1) cjelokupnom kombinovanom skupu podataka i (2) samo jednom skupu — CREMA-D. Testiranje je izvršeno na nezavisnim skupovima koji nisu korišćeni u treniranju: Emotional Speech database (EmoDB) za audio modalitet (na njemačkom jeziku) i RAVDESS za vizuelni modalitet. U svrhu dodatne evaluacije robusnosti, slike lica iz RAVDESS skupa su modifikovane dodavanjem Gaussian buke i varijacijama osvetljenja (engl. *color jitter*), kako bi se simulirali uslovi lošijeg kvaliteta snimka. Oba skupa uključuju ravnomjeren polni balans (50% žena), dok RAVDESS pokriva različite etničke grupe (azijsku i kavkasku).
- **Modalitet-specifična evaluacija:** Da bi se utvrdio relativni doprinos audio i vizuelnog kanala ukupnim performansama sistema (**IP2**), svaki modalitet je evaluiran nezavisno, zadržavajući istu arhitekturu, ali isključujući drugi kanal.

Modeli su evaluirani koristeći metriku tačnosti klasifikacije, definisanu formulom:

$$\text{Preciznost} = \frac{TP + TN}{TP + TN + FP + FN}, \quad (5.2)$$

gdje su TP (engl. *true positives*) tačno klasifikovani pozitivni primjeri, TN (engl. *true negatives*) tačno klasifikovani negativni primjeri, FP (engl. *false positives*) pogrešno označeni pozitivni primjeri i FN (engl. *false negatives*) promašeni pozitivni primjeri. Tačnost predstavlja udio ispravno klasifikovanih instanci u odnosu na ukupan broj instanci u skupu podataka. Pored toga, korišćena je i matrica konfuzije (engl. *Confusion Matrix (CM)*), koja omogućava detaljan uvid u ponašanje sistema po klasama. Matrica konfuzije je dvodimenzionalna tabela u kojoj se redovi odnose na stvarne klase, a kolone na predviđene klase. Element C_{ij} označava broj instanci koje pripadaju stvarnoj klasi i , a koje su modelom predviđene kao klasa j .

Na taj način je moguće identifikovati koje klase model razlikuje dobro, a kod kojih dolazi do čestih grešaka. Ove metrike su usklađene sa standardima u oblasti automatskog prepoznavanja emocija i doprinose transparentnosti rezultata.

6. Rezultati

Radi procjene performansi primijenjene su različite evaluacione strategije. Prva je cross-corpus evaluacija, koja procjenjuje sposobnost generalizacije na potpuno nove skupove, sa različitim govornicima, okruženjima i načinima izražavanja emocija. Ovaj pristup pruža realističniju i strožu procjenu robusnosti sistema. Druga strategija je holdout testiranje, gdje je objedinjeni skup podataka podijeljen na trening, validacioni i test podskup, čime se dobijaju rezultati unutar iste distribucije podataka.

U nastavku su prikazani rezultati po pojedinačnim modalitetima, kao i multimodalnom fuzijom.

6.1. Generalizacija facijalnog modela

Kao što je prikazano u Tabeli 2, treniranje na raznovrsnom skupu značajno je poboljšalo generalizaciju. Model treniran na objedinjeni skup podataka postigao je tačnost od 61.67%, dok je model treniran samo na CREMA-D postigao svega 47.14%.


Trening skup	Test skup	Tačnost
Objedinjeni	RAVDESS	61.67%
CREMA-D	RAVDESS	47.14%

Tabela 2: Tačnost facijalnog modela na RAVDESS (cross-corpus)

Slika 4 ilustruje performanse generalizacije facijalnog modela, treniranih na objedinjeni skup. Facijalni model ostvaruje bolje rezultate u prepoznavanju emocija sa izraženim vizuelnim manifestacijama, kao što su *Sreća* i *Gađenje*, dok je kod emocija poput *Straha* i *Tuge* stopa tačne klasifikacije niža.

Jedan od mogućih razloga je to što mikroekspresije i suptilne promjene u izrazu lica mogu biti teško uočljive, posebno kada se trenira na skupovima sa promjenljivim osvjetljenjem i po-

zicijama lica. Rezultati ukazuju da vizuelni modalitet uspješno detektuje statičke karakteristike izraza, ali ima poteškoća sa kontekstualnim ili prelaznim emocijama.



Slika 4: Normalizovane matrice konfuzije za facijalni model u cross-corpus evaluaciji (trenirani na objedinjeni skup, testirani na EmoDB i RAVDESS).

6.2. Generalizacija audio modela

Audio model je pokazao slične rezultate (Tabela 3). Model treniran na objedinjeni skup bolje se generalizovao na EmoDB (56.17%) u poređenju s modelom treniranim samo na CREMA-D (35.90%).

Trening skup	Test skup	Tačnost
Objedinjeni	EmoDB	56.17%
CREMA-D	EmoDB	35.90%


Tabela 3: Tačnost audio modela na EmoDB (cross-corpus)

Slika 5 ilustruje performanse generalizacije audio modela, treniranih na objedinjeni skup. Modeli se međusobno nadopunjuju pri prepoznavanju emocija kao što su *Ljutnja*, *Gađenje* i

Sreća. Normalizovane matrice konfuzije jasno pokazuju obrasce pogrešne klasifikacije audio modela prilikom evaluacije na skupovima EmoDB i RAVDESS.

Model postiže visoku tačnost u prepoznavanju izraženih emocija poput *Ljutnje* i *Sreće*, dok emocije poput *Tuge* i posebno *Straha* bilježe veći broj pogrešnih klasifikacija, što može biti posljedica akustičkih sličnosti sa neutralnim ili drugim negativnim emocijama. Ovakva raspodjela grešaka sugerira da sam modalitet govora, bez vizuelnog konteksta, može biti nedovoljno robustan za bolju definisanost razlika između emocija sa sličnim karakteristikama.

Dodatno, primjećuje se da kvalitet i raznovrsnost podataka na kojima se modeli treniraju imaju značajan uticaj na stabilnost performansi, jer različiti govornici, jezičke specifičnosti i stilovi govora mogu unijeti varijabilnost koja otežava učenje jasnih granica između kategorija. Zbog toga se otvara prostor za integraciju multimodalnih pristupa, gdje bi kombinacija audio i vizuelnih informacija mogla obezbijediti bolju otpornost sistema na pogrešne klasifikacije i povećati pouzdanost u realnim primjenama.



Slika 5: Normalizovane matrice konfuzije za audio model u cross-corpus evaluaciji (trenirani na objedinjeni skup, testirani na EmoDB i RAVDESS).


6.3. Generalizacija modela fuzije

Model fuzije dosljedno nadmašuje pojedinačne modele čak i na neviđenim podacima. Kada je treniran na objedinjeni skup, a testiran na EmoDB i RAVDESS, dostigao je tačnost od 72.03% (Tabela 4), što jasno pokazuje prednosti multimodalne strategije i kasne fuzije.

Trening skup	Test skupovi	Tačnost
Objedinjeni	EmoDB (audio), RAVDESS (facijalni)	72.03%
CREMA-D	EmoDB (audio), RAVDESS (facijalni)	47.58%

Tabela 4: Tačnost modela fuzije na EmoDB + RAVDESS (cross-corpus)

Slika 6 prikazuje performanse fuzionog modela na neviđenim podacima. Fuzioni model pokazuje jasna poboljšanja u odnosu na pojedinačne modalitete, što potvrđuje prednosti kasne fuzije u multimodalnim pristupima. Dok i dalje postoje izazovi u prepoznavanju emocije *Strah*, ukupna raspodjela klasifikacija je znatno uravnoteženija. Emociju *Strah* je najteže prepoznati, sa samo 43% ispravno klasifikovanih uzoraka. Primjetno je da se greške karakteristične za audio model (npr. miješanje *Straha* sa *Tugom*) i facijalni model (npr. zamjena *Tuge* sa neutralnim izrazom) međusobno kompenzuju, čime se postiže bolja ukupna tačnost.




Slika 6: Normalizovana matrica konfuzije za fuzioni model u cross-corpus evaluaciji (trenirano na objedinjeni skup, testirano na EmoDB i RAVDESS).

6.4. Uporedna analiza

Za razliku od prethodnih rezultata cross-corpus evaluacije, ovdje su prikazani rezultati holdout testiranja nad objedinjenim skupom podataka. Slika 7 prikazuje tačnosti testiranja za svaki modalitet koristeći objedinjeni skup podataka. Budući da treniranje i testiranje potiču iz iste distribucije podataka, model fuzije značajno nadmašuje pojedinačne audio i facijalne modele, postižući tačnost od 82.36%. Ovi rezultati potvrđuju hipotezu da multimodalno učenje poboljšava prepoznavanje emocija.

Dodatno, ovaj nalaz je u skladu sa analizama iz prethodnih sekcija, gdje je pokazano da svaki modalitet ima specifične slabosti (npr. poteškoće facijalnog modela kod suptilnih emocija ili audio modela kod akustički sličnih emocija), koje se nadoknađuju njihovim kombinovanjem.



Slika 7: Performanse modela na test podskupu objedinjenih podataka

7. Budući pravci istraživanja

U daljem radu, planirano je:

- **Uvođenje fizioloških signala** (npr. puls, *Electrodermal Activity (EDA)*) kao dodatnog modaliteta za robusniju detekciju emocionalnih stanja, što bi omogućilo kreiranje multimodalnih sistema sa većom pouzdanošću i otpornosti na šum iz pojedinačnih izvora podataka;
- **Sprovođenje formalne analize pristrasnosti** u performansama modela u odnosu na pol, starost i kulturni kontekst. Ovakva analiza je ključna za osiguranje pravičnosti i generalizabilnosti sistema, imajući u vidu značajne razlike u distribuciji aktera unutar javno dostupnih skupova podataka (Tabela 5);

Skup podataka	Muški akteri	Ženski akteri	Balans
CREMA-D	48	43	Ravnoteža
RAVDESS	12	12	Ravnoteža
eNTERFACE	34	9	Disbalans
SAVEE	4	0	Nedostatak ženskih aktera
AffectNet	140k	143k	Ravnoteža

Tabela 5: Analiza prisutnosti disbalansa polova kod različitih skupova podataka

- **Testiranje i validacija u kliničkim uslovima**, kroz saradnju sa zdravstvenim institucijama, uz odgovarajuće etičke dozvole i protokole. Ova faza je od presudne važnosti kako bi

se procijenila upotrebljivost sistema u realnom okruženju i dobio uvid u praktične izazove pri radu sa pacijentima;

- **Optimizacija za ugrađene uređaje**, radi implementacije u sistemima za diskretni nadzor u okruženjima za njegu starih lica [34], sa fokusom na smanjenje potrošnje resursa i očuvanje performansi u realnom vremenu.

Posebnu pažnju u budućim istraživanjima zaslužuju etička razmatranja i obrasci za očuvanje privatnosti korisnika, uključujući:

- **Lokalnu obradu podataka** – svi procesi se izvršavaju na lokalnom uređaju, bez slanja podataka u Cloud, čime se garantuje privatnost pacijenata;
- **Bez skladištenja sirovih podataka** – umesto audio ili video zapisa, sistem beleži isključivo emocije oznake (npr. tuga, sreća), koje se koriste za uočavanje trendova i analiza emotivnih stanja tokom vremena. Ovi zapisi se čuvaju lokalno, uz primenu enkripcije;
- **Analizu raspoloženja zasnovanu na vremenskim obrascima** – interpretacija emocija se ne bazira samo na trenutnim izražajima, već i na longitudinalnom posmatranju, što omogućava kontekstualno svesnu podršku;
- **“Stop dugme” za medicinsko osoblje** – ideja o implementaciji fizičkog ili digitalnog tastera kojim bi se monitoring mogao odmah zaustaviti, čime se obezbeđuje autonomija pacijenata i poštovanje etičkog principa saglasnosti;
- **Obrasci za saglasnost pacijenata** – razvoj protokola koji bi omogućili jasno i informisano davanje i povlačenje saglasnosti za korišćenje sistema u kliničkoj i kućnoj njezi.

8. Zaključak

U ovom radu predstavljen je efikasan i proširiv sistem za automatsko prepoznavanje emocija (MER), koji kombinuje facijalne i audio modalitete koristeći MobileNetV2 arhitekture i kasnu fuziju predikcija. Cilj sistema bio je detekcija šest osnovnih emocionalnih stanja, sa posebnim fokusom na negativne izraze koji mogu ukazivati na fizičke i psihološke simptome demencije (BPSD) [34, 3].

Rezultati eksperimentalne evaluacije ukazuju na dva ključna zaključka:

- **Raznovrstan i heterogen skup podataka** za treniranje modela značajno poboljšava sposobnost generalizacije modela na nepoznate govornike i okruženja.
- **Multimodalna obrada sa kasnom fuzijom** dosljedno nadmašuje unimodalne pristupe, naročito u uslovima degradacije jedne od modaliteta, što je od posebnog značaja u kliničkim i kućnim uslovima gde podaci mogu biti nepotpuni ili bučni.

Fuzion model je na neviđenim skupovima podataka postigao tačnost od **72.03%**, što jasno pokazuje potencijal ovog pristupa za pasivno praćenje emocionalnog stanja u stvarnim okruženjima. Međutim, postoje i ograničenja. Upotreba oponašanih (*engl. acted*) skupova podataka može ograničiti primenljivost sistema na suptilne, spontane emocije karakteristične za osobe sa demencijom [6]. Takođe, analiza pristrasnosti u performansama prema polu i drugim demografskim faktorima nije sprovedena, što otvara prostor za buduće etički odgovorno usavršavanje sistema.

Zaključno, predstavljeni sistem pokazuje značajan potencijal za primjenu u emocionalno svjesnim asistivnim tehnologijama, ali je za njegovu potpunu validaciju i prelazak u kliničku praksu neophodan balans između tehničkih inovacija, etičkih standarda i zaštite privatnosti korisnika.

Literatura

- [1] Panagiotis C. Petrantonakis i Leontios J. Hadjileontiadis. “Emotion Recognition from Brain Signals Using Hybrid Adaptive Filtering and Higher Order Crossings Analysis”. U: *IEEE Transactions on Affective Computing* 1.2 (2010.), str. 81–97. DOI: 10.1109/T-AFFC.2010.7.
- [2] William James. *The Principles of Psychology, Volume 1 (of 2)*. eng. Project Gutenberg, 2007.
- [3] Yujian Cai, Xingguang Li, i Jinsong Li. “Emotion Recognition Using Different Sensors, Emotion Models, Methods and Datasets: A Comprehensive Review”. U: *Sensors* 23.5 (2023.). PubMed ID: 36904659. ISSN: 1424-8220. DOI: 10.3390/s23052455. URL: <https://www.mdpi.com/1424-8220/23/5/2455>.
- [4] Satyajit Nayak i dr. “A Human–Computer Interaction framework for emotion recognition through time-series thermal video sequences”. U: *Computers Electrical Engineering* 93 (2021.), str. 107280. ISSN: 0045-7906. DOI: <https://doi.org/10.1016/j.compeleceng.2021.107280>. URL: <https://www.sciencedirect.com/science/article/pii/S0045790621002627>.
- [5] Rajamanickam Yuvaraj i dr. “Review of Emotion Recognition in Stroke Patients”. eng. U: *Dementia and geriatric cognitive disorders* 36.3-4 (2013.), str. 179–196. ISSN: 1420-8008.
- [6] Shan Li i Weihong Deng. “Deep Facial Expression Recognition: A Survey”. U: *IEEE Transactions on Affective Computing* 13.3 (2022.), str. 1195–1215. DOI: 10.1109/T-AFFC.2020.2981446.
- [7] Suzanne M. Dyer i dr. “Clinical practice guidelines and principles of care for people with dementia in Australia”. U: *Australian Family Physician* 45.12 (dec. 2016.). PubMed ID:

-
- 27903038, str. 884–889. ISSN: 0300-8495. URL: <https://pubmed.ncbi.nlm.nih.gov/27903038/>.
- [8] Paolo Mazzarello. “Alois Alzheimer and the birth of dementia research”. U: *The Lancet* 356.9228 (2000.), str. 1864. DOI: 10.1016/S0140-6736(00)03281-2.
- [9] Nicole C. Berchtold i Carl W. Cotman. “The evolution of the conceptualization of dementia and Alzheimer’s disease: 19th to 21st century”. U: *Neurobiology of Aging* 34.1 (2013.), S3–S9. DOI: 10.1016/j.neurobiolaging.2012.09.018.
- [10] National Health and Medical Research Council. *Clinical practice guidelines and principles of care for people with dementia*. <https://www.nhmrc.gov.au/about-us/publications/dementia-guidelines>. Accessed: 2025-07-17. 2016.
- [11] Alireza Ghorbanali i Mohammad Karim Sohrabi. “A comprehensive survey on deep learning-based approaches for multimodal sentiment analysis”. U: *Artificial Intelligence Review* 56 (2023.), str. 1479–1512.
- [12] Shirley Chow i dr. “Nonpharmacological approaches for managing behavioral and psychological symptoms of dementia: a systematic review”. U: *International Journal of Geriatric Psychiatry* 37.3 (2022.), str. 1–14. DOI: 10.1002/gps.5683.
- [13] Paul Ekman i dr. “Universals and Cultural Differences in the Judgments of Facial Expressions of Emotion”. eng. U: *Journal of personality and social psychology* 53.4 (1987.), str. 712–717. ISSN: 0022-3514.
- [14] Taciana Saad Rached i Angelo Perkusich. “Emotion Recognition Based on Brain-Computer Interface Systems”. U: *Brain-Computer Interface Systems*. Urednik Reza Fazel-Rezai. Rijeka: IntechOpen, 2013. Glava 13. DOI: 10.5772/56227. URL: <https://doi.org/10.5772/56227>.
- [15] Smith K. Khare i dr. “Emotion recognition and artificial intelligence: A systematic review (2014–2023) and research recommendations”. eng. U: *Information fusion* 102 (2024.), str. 102019–. ISSN: 1566-2535.
- [16] James A Russell. “A circumplex model of affect.” U: *Journal of personality and social psychology* 39.6 (1980.), str. 1161.

-
- [17] Gustave Udaheureka, Karim Djouani, i Anish M Kurien. “Multimodal Emotion Recognition using visual, vocal and Physiological Signals: a review”. U: *Applied Sciences* 14.17 (2024.), str. 8071. DOI: 2076-3417/14/17/8071. URL: <https://www.mdpi.com/2076-3417/14/17/8071>.
- [18] S. Sahu i dr. “A systematic survey on multimodal emotion recognition using deep learning architectures”. U: *Visual Informatics* 6 (2022.), str. 1–15.
- [19] A. Author i B. Author. “Deep learning-based multimodal emotion recognition from audio-visual cues: Recent advancements”. U: *Expert Systems with Applications* 200 (2023.), str. 117000.
- [20] M Srihari i V Bhaskaran. “A Multimodal Fusion Approach: Emotion Identification from Audio and Video Using Convolutional Neural Network”. U: *2024 IEEE International Conference on Computer Vision and Machine Intelligence (CVMi)*. IEEE. 2024., str. 1–5.
- [21] Maxim Sidorov i dr. “Feature and decision level audio-visual data fusion in emotion recognition problem”. U: *2015 12th International Conference on Informatics in Control, Automation and Robotics (ICINCO)*. Sv. 2. IEEE. 2015., str. 246–251.
- [22] Mateusz Wozniak i dr. “Bimodal Emotion Recognition Based on Vocal and Facial Features”. U: *Procedia Computer Science* 225 (2023.). 27th International Conference on Knowledge Based and Intelligent Information and Engineering Systems (KES 2023), str. 2556–2566. ISSN: 1877-0509. DOI: <https://doi.org/10.1016/j.procs.2023.10.247>. URL: <https://www.sciencedirect.com/science/article/pii/S1877050923014059>.
- [23] Kaan Aktürk i Ali Seydi Keçeli. “Deep operational audio-visual emotion recognition”. U: *Neurocomputing* 588 (2024.), str. 127713.
- [24] Steven R. Livingstone i Frank A. Russo. “The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS)”. U: *PloS one* 13.5 (2018.), e0196391. DOI: 10.1371/journal.pone.0196391.
- [25] Hu Cao i dr. “CREMA-D: Crowd-sourced Emotional Multimodal Actors Dataset”. U: *IEEE Transactions on Affective Computing* 5.4 (2014.), str. 377–390. DOI: 10.1109/TAFFC.2014.2336244.
- [26] Ian Goodfellow i dr. *Challenges in Representation Learning: A report on three machine learning contests*. arXiv preprint arXiv:1307.0414. 2013.

-
- [27] Carlos Busso i dr. "IEMOCAP: Interactive emotional dyadic motion capture database". U: *Language Resources and Evaluation* 42.4 (2008.), str. 335–359. DOI: 10.1007/s10579-008-9076-6.
- [28] Shiqi Wang i dr. *Emotion Recognition Using Multimodal Deep Learning*. <https://www.kaggle.com/datasets/uwrfkaggler/ravdess-emotional-speech-audio>. 2016.
- [29] Abhinav Dhall i dr. "Collecting Large, Richly Annotated Facial-Expression Databases from Movies". U: *IEEE Multimedia and Expo (ICME)*. 2013., str. 1–6. DOI: 10.1109/ICME.2013.6607583.
- [30] Olivier Martin i dr. "The eNTERFACE'05 Audio-Visual Emotion Database". U: *Proceedings of the 22nd International Conference on Data Engineering Workshops*. 2006., str. 8–8. DOI: 10.1109/ICME.2006.1689098.
- [31] Suleman Haq i Peter JB Jackson. "Speaker-dependent audio-visual emotion recognition". U: *Audio, Speech, and Language Processing, IEEE Transactions on* 16.1 (2009.), str. 91–103. DOI: 10.1109/TASL.2007.911513.
- [32] Felix Burkhardt i dr. "A Database of German Emotional Speech". U: *Interspeech* (2005.), str. 1517–1520.
- [33] Ali Mollahosseini, Behzad Hasani, i Mohammad H. Mahoor. "AffectNet: A Database for Facial Expression, Valence, and Arousal Computing in the Wild". U: *IEEE Transactions on Affective Computing* 10.1 (2019.), str. 18–31. DOI: 10.1109/TAFFC.2017.2740923.
- [34] Mark Sandler i dr. "MobileNetV2: Inverted Residuals and Linear Bottlenecks". eng. U: *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. IEEE, 2018., str. 4510–4520. ISBN: 9781538664209.